
# **DLP HW6**

### 數據所 311554019 宋沛潔

- 1. The screenshot of tensorboard and testing results on LunarLander-v2:
- DDPG:
  - 1. Testing results:

```
Start Testing
Episode: 0
                Total reward: 246.25
Episode: 1
                Total reward: 277.18
Episode: 2
                Total reward: 276.51
Episode: 3
                Total reward: 269.20
Episode: 4
                Total reward: 294.21
Episode: 5
                Total reward: 272.64
Episode: 6
                Total reward: 289.73
Episode: 7
                Total reward: 171.66
Episode: 8
                Total reward: 188.48
Episode: 9
                Total reward: 254.63
Average Reward 254.04842568562708
```


Tensorboard



- DQN
  - 1. Testing results:

```
Start Testing
Episode: 0
                Total reward: 284.48
Episode: 1
                Total reward: 294.43
Episode: 2
                Total reward: 280.39
Episode: 3
                Total reward: 304.09
                Total reward: 243.91
Episode: 4
Episode: 5
                Total reward: 282.68
Episode: 6
                Total reward: 283.87
Episode: 7
                Total reward: 229.52
Episode: 8
                Total reward: 294.35
Episode: 9
                Total reward: 279.68
Average Reward 277.739862397647
```

#### 2. Tensorboard:




# 2. The screenshot of tensorboard and testing results on BreakoutNoFrameskip-v4:

## 1. Testing results:



#### 2. Tensorboard:



# 3. Questions:

### 3.1. Describe both DQN and DDPG in detail

### • DQN:

Behavior network 會根據當前 state 選擇 action,而 target network 則是

用來計算目標值。其中,Behavior network 目標是使用 replay memory 來存儲過去 agent 在環境的經驗,透過在訓練過程中進行隨機抽樣。並用下方公式計算目標值,在以 MSE 更新網路。

$$Y_t^Q = r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a'|\theta)$$

再來是 target network, 他主要是每幾個 steps 去複製 behavior network 權重,為的是穩定訓練過程,不會在每個 steps 都直接使用 behavior network 的目標值來更新網絡的權重

如果隨機數小於 epsilon,隨機抽樣一個動作,如果大於 epsilon 會從 behavior network 來選擇一個最有可能是最大 Q 值的 action。這個設計可以同時實施 exploration 及 exploitation。在訓練過程中,希望能夠對動作空間進行 exploration,以發現更好的策略。

```
def select_action(self, state, epsilon, action_space):
    '''epsilon-greedy based on behavior network'''
    ## TODO ##
    if random.random() <= epsilon:
        action = action_space.sample()
    else:
        with torch.no_grad():
            input_state = torch.from_numpy(state).to(self.device)
            actions_vec = self._behavior_net(input_state)
            action = torch.argmax(actions_vec).item()
    return action</pre>
```

#### DDPG:

ActorNet 是去學習特徵,幫助網絡更好選擇 action。這邊設計兩個全連接層接著 ReLU activation function,最後一層接 Tanh activation function。

```
class ActorNet(nn.Module):
   def __init__(self, state_dim=8, action_dim=2, hidden_dim=(400, 300)):
       super().__init__()
       ## TODO ##
       self.layer1 = nn.Linear(state_dim, hidden_dim[0])
       self.layer2 = nn.Linear(hidden_dim[0], hidden_dim[1])
       self.layer3 = nn.Linear(hidden_dim[1], action_dim)
       self.relu = nn.ReLU()
       self.tanh = nn.Tanh()
   def forward(self, x):
       x = self.layer1(x)
       x = self.relu(x)
       x = self.layer2(x)
       x = self.relu(x)
       x = self.layer3(x)
       x = self.tanh(x)
```

CriticNet 會根據當前 state 和由 ActorNet 選擇的 action,來估計 Q 值,也就是預測在該狀態下執行該動作的預期 Q 值。

Behavior network 會根據當前 state 選擇 action,而 target network 則是用來計算目標值。

首先,使用 critic network 計算當前 State 下的 action 的 Q 值。再根據 target critic network 計算下一個 State 及 target actor network 選擇的動作的 Q 值。接著使用 MSE 作為 loss function 來更新 behavior critic network,最後用 ActorLoss 來更新 behavior actor network。

```
def _update_behavior_network(self, gamma):
    actor_net, critic_net, target_actor_net, target_critic_net = self._actor_net, self._critic_net, self._target_actor_net, self._target_critic_net
    actor_not, critic_net = self._actor_net, self._critic_net

# sample a minibatch of transitions
    state, action, reward, next_state, done = self._memory.sample(
        self.butch_size, self.device)

## update critic ##
# critic loss
## TOOD ##

q_value = self._critic_net(state, action)
    with torch.no_grad():
        a_next = self._target_actor_net(next_state)
        q_next = self._target_actor_net(next_state, a_next)
        q_target = reward = gamma * q_next * (1 - done)
    criterion = nn.MSELoss()
    critic_loss = criterion(q_value, q_target)
    # optimize critic
    actor_net.zero_grad()
    critic_loss.backward()
    critic_loss.backward()
    critic_loss.backward()
    critic_loss.backward()
    soptimize actor
    actor_net.zero_grad()
    actor_loss = -self._critic_net(state, action).mean()
## optimize actor
    actor_net.zero_grad()
    actor_net.zero_grad()
    actor_net.zero_grad()
    actor_net.zero_grad()
    actor_loss.backward()
    actor_loss.backwar
```

在 target network 中直接複製權重可能會導致模型更新不穩定,所以使用 soft copy 來更新 target network。將 behavior network 的權重以一定的比例  $\tau$  融合到 target network 的權重中。

#### 3.2. Explain the necessity of the target network

Target network 他主要是每幾個 steps 去複製 behavior network 權重,為的是穩定訓練過程,不會在每個 steps 都直接使用 behavior network 的目標值來更新網絡的權重。這可以解決 overestimation,因為 behavior network 的估計值可能有時會過高,導致對於目標值的估計也會偏高,造成訓練結果不穩定。因此加了 target network 可以增加穩定性,使得模型能夠更好地學習到最佳策略。

#### 3.3. Explain effects of the discount factor

discount factor 用來調整未來 reward 的價值。範圍在  $0\sim1$ ,在這份程式 gamma。如果 discount factor 接近 1,代表未來的 reward 對當前影響越大,來關注未來的 reward,幫助學到更長期的策略,更有機會得到更好的結果;而 discount factor 越接近 0,代表未來的獎勵對當前影響越小,agent 較在意當下即時策略。

# 3.4. Explain benefits of epsilon-greedy in comparison to greedy action selection

epsilon-greedy的概念是,如果隨機數小於 epsilon,隨機抽樣一個動作,如果 大於 epsilon 會從 behavior network 來選擇一個最有可能是最大 Q 值的 action。這個設計可以同時實施 exploration 及 exploitation。在訓練過程中,希 望能夠對動作空間進行 exploration,以發現更好的策略。 因此跟 greedy action selection 比較下, epsilon-greedy 更可以探索不同的策略 來避免只有找到局部最佳解,能夠獲得更好的去學習最佳策略。

# 3.5. Describe the tricks you used in Breakout and their effects, and how they differ from those used in LunarLander

有使用助教 PPT 上提供的 frame stacking 的技術。讓模型看到遊戲的動態,而不是只有單一張。模型會將 4 個連續的 frame 堆疊在一起,形成一個具有時間序列的 state。

agent 在每一輪遊戲的開始時執行 10 次 Atari 遊戲中的 action 0。也就是給遊戲從初始 state 有一些隨機性,避免 agent 只有學會一種固定的遊戲開始策略,增加 exploration。

```
def train(args, agent, writer):
    print("Start Training")
    env = make_atari("BreakoutNoFrameskip-v4')
    env = wrap_deepmind(env_raw, episode_life=True, clip_rewards=True)
    action_space = env.action_space
    total_steps, epsilon = 0, 1.
    ewma_reward = 0
    queue = deque(maxlen=5)

for episode in range(args.episode):
    total_reward = 0
    state = env.reset()
    state, reward, done, _ = env.step(1) # fire first !!!
    for _ in range(18):
        result = env.step(0)
        frames = frame(result[0])
        queue.append(frames)

## 1000 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 500 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

## 600 ##

##
```